

Лекция 5

Метрики качества и линейная регрессия

Дисбаланс классов · ошибки прогноза · градиентный спуск

Лектор

Елизавета Власова

Практики

Кирилл Захаров

Михаил Подсытник

Игорь Толстокулаков

Сегодня за 90 минут

0–24 мин Матрица ошибок, дисбаланс, precision/recall, порог, ROC/PR

24–36 мин MAE, MSE, RMSE и R^2 на числовом прогнозе

36–55 мин Прямая, остатки, MSE и параметры линейной модели

55–75 мин Производная, шаг градиентного спуска и размер шага

75–90 мин Ridge, Lasso, выбор λ и итоги

Вопросы про kNN и разбиение данных используем в примерах, без повторения предыдущих разделов.

Метрики классификации

Разные ошибки требуют разных измерений

Accuracy при редком классе

На проверке 100 писем. Модель всегда отвечает: «обычное письмо».



$$\text{Accuracy} = \frac{\text{число верных ответов}}{\text{число всех объектов}}.$$

Какая здесь ассигасу? Сколько спама модель обнаружила?

Одинаковые данные, разные ошибки


Модель A: accuracy 96%



Найдено спама: 3 из 5

Обычных писем заблокировано: 2

Модель B: accuracy 91%



Найдено спама: 4 из 5

Обычных писем заблокировано: 8

Красный — спам, синий — обычное. Обводка — предсказали «спам».

У ответа «всё обычное» accuracy 95%, найдено 0 из 5.

Accuracy скрывает, какие именно объекты модель пропускает.

Матрица ошибок и метрики

Confusion matrix: модель B, $N = 100$ писем; положительный класс — спам.

Истина	Предсказание	
	Спам	Обычное
Спам	TP = 4	FN = 1
Обычное	FP = 8	TN = 87

TP / TN: верные ответы.

FP: обычное письмо заблокировано.

FN: спам пропущен.

Accuracy

$$\frac{TP + TN}{N} = \frac{4 + 87}{100} = 91\%$$

Precision

$$\frac{TP}{TP + FP} = \frac{4}{12} \approx 33.3\%$$

Recall / TPR

$$\frac{TP}{TP + FN} = \frac{4}{5} = 80\%$$

F1

$$\frac{2TP}{2TP + FP + FN} = \frac{8}{17} \approx 0.47$$

FPR

$$\frac{FP}{FP + TN} = \frac{8}{95} \approx 8.4\%$$

Specificity / TNR

$$\frac{TN}{TN + FP} = \frac{87}{95} \approx 91.6\%$$

Precision и recall: разные знаменатели

Отобрали 12 писем



$$P = \frac{TP}{TP + FP} = \frac{4}{12} \approx 33\%.$$

Доля настоящего спама среди **выбранных** писем.


Всего 5 спам-писем



$$R = \frac{TP}{TP + FN} = \frac{4}{5} = 80\%.$$

Доля найденных среди **всех** спам-писем.

F1: совместная оценка precision и recall




$$F_1 = \frac{2PR}{P + R} = \frac{2TP}{2TP + FP + FN}$$

Для B: $F_1 = 8/17 \approx 0.47$. У A: $F_1 = 0.60$.

F1 учитывает обе ошибки, но не задаёт их цену для задачи.

Score и порог решения

Теперь 8 объектов: четыре положительных и четыре отрицательных.




$$\hat{y} = 1[s(x) \geq t].$$

В kNN score можно получить как долю голосов класса 1.

При $t = 0.70$ посчитайте TP, FP, FN и TN.

Что меняется при снижении порога



При $t = 0.70$: $TP = 3$, $FP = 1$, $FN = 1$, $TN = 3$.

Порог ниже — больше объектов отбираем, больше положительных находим.

Precision при этом может как снижаться, так и расти.

Один порог — одна точка ROC


Порог $t = 0.70$:

нашли 3 из 4 положительных;

ошиблись на 1 из 4 отрицательных.


$$\text{TPR} = \frac{TP}{TP + FN} = \frac{3}{4}.$$

$$\text{FPR} = \frac{FP}{FP + TN} = \frac{1}{4}.$$



FPR — доля ошибок среди всех отрицательных объектов. Это другой знаменатель, чем у precision.



Построение ROC-кривой



Порядок по score: A, B, C, D, E, F, G, H.

Положительный: шаг вверх на $1/4$. Отрицательный: вправо на $1/4$.

ROC-AUC: площадь и правильные пары



$$AUC = \frac{\text{пар, где score положительного выше}}{\text{всех пар}} = \frac{11}{16} = 0.6875.$$

AUC = 1: идеальный порядок. 0.5: случайный порядок в среднем. 0: обратный.

Каждый порог даёт точку PR-кривой

Те же восемь объектов, упорядоченные по score:


$A^+, B^-, C^+, D^+, E^-, F^-, G^+, H^-$.

Выбраны при пороге	TP	Precision = $TP/(TP + FP)$	Recall = $TP/4$
A	1	$1/1 = 1$	$1/4$
A, B	1	$1/2$	$1/4$
A, B, C	2	$2/3$	$2/4$
A, B, C, D	3	$3/4$	$3/4$
A, ..., G	4	$4/7$	$4/4$

При снижении порога recall не убывает; precision может и падать, и расти.

Координаты PR-кривой

На горизонтальной оси — recall, на вертикальной — precision. Каждая точка соответствует порогу; при равном recall возможны разные значения precision.



При $t = 0.70$ выбраны A, B, C, D :

$TP = 3, FP = 1, FN = 1.$

$Recall = 3/4, Precision = 3/4.$

Горизонтальный ориентир $4/8 = 0.5$
— доля положительных объектов в этом примере.

Average precision суммирует ранжирование

AP усредняет precision в те моменты, когда найден очередной положительный объект:

$$AP = \sum_k (R_k - R_{k-1}) P_k.$$


У четырёх положительных объектов A, C, D, G каждый прирост recall равен $1/4$:

$$AP = \frac{1}{4} \left(1 + \frac{2}{3} + \frac{3}{4} + \frac{4}{7} \right) \approx 0.747.$$

AP и геометрическая площадь под PR-кривой, вычисленная трапециями, могут различаться. Указываем, какой способ суммирования использовали.

ROC-AUC при редком классе

Две выборки по 10 000 объектов. Кривые ROC совпадают.




Состав срабатываний при одном пороге

Положительных 50%: 4000 TP + 500 FP



Положительных 1%: 80 TP + 990 FP



При доле 1%: из 1 070 срабатываний только 80 верны.

Для редкого класса проверяем precision и рабочий порог.

Дисбаланс классов

На 10 000 объектах класс 1 встречается в 1% случаев. Модель, которая всегда отвечает «0», имеет accuracy 99%, но не находит ни одного положительного объекта.

- ▶ Доля классов меняет число FP при той же FPR: $\text{precision} = \frac{\text{TPR} \pi}{\text{TPR} \pi + \text{FPR}(1 - \pi)}$, где π — доля класса 1.
- ▶ Сначала задаём рабочую метрику и выбираем порог на validation.
- ▶ Способы изменения train сравниваем на исходной validation и test.

Выбор при редком классе

Для автоматической блокировки письма нужна $\text{precision} \geq 90\%$. На validation:

Порог	Precision	Recall
t_1	96%	35%
t_2	91%	70%
t_3	78%	88%

Какой порог даст наибольший recall при выполнении условия?

Ответ: t_2 ; после выбора один раз проверяем на test. Ресемплинг train не заменяет выбор рабочего порога.

2

Метрики регрессии

Насколько далеко прогноз от истинного числа

Числовой прогноз

Задача: по признакам образца предсказать концентрацию вещества (мг/л).

Образец	A	B	C
y	2	4	6
$\hat{y}$	3	4	5
Ошибка $e = \hat{y} - y$	+1	0	-1

Класса «верно/неверно» нет: величина ошибки имеет значение. Считаем метрики на отложенных объектах.

MAE: средняя абсолютная ошибка

$$\text{MAE} = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|.$$

Для трёх образцов: $\text{MAE} = (1 + 0 + 1)/3 = 2/3$ мг/л.

- ▶ Читаем в тех же единицах, что и target.
- ▶ Большая ошибка растёт линейно: ошибка 4 вносит вклад в 4 раза больше ошибки 1.
- ▶ Если все ошибки одинаково дороги за единицу отклонения, MAE легко интерпретировать.

MSE и RMSE: большие ошибки сильнее

$$\text{MSE} = \frac{1}{n} \sum_i (y_i - \hat{y}_i)^2, \quad \text{RMSE} = \sqrt{\text{MSE}}.$$

Для примера: $\text{MSE} = (1 + 0 + 1)/3 = 2/3 \text{ (мг/л)}^2$, $\text{RMSE} \approx 0.82 \text{ мг/л}$.

Модуль ошибки	Вклад в MAE	Вклад в MSE
1	1	1
4	4	16

При фиксированном наборе данных минимизация MSE и RMSE выбирает одинаковую модель.

Baseline для регрессии

Без признаков предсказываем одно число каждому объекту. Для MSE лучшая константа на train — среднее $\bar{y}_{train}$; для MAE — медиана train. В нашем

примере $y = (2, 4, 6)$: среднее равно 4. Константный прогноз (4, 4, 4) даёт $SSE = 4 + 0 + 4 = 8$. **В реальном эксперименте** среднее вычисляем по train и

сравниваем модели на validation/test. Здесь числа на одной маленькой выборке нужны только для расчёта.

R^2 : сравнение с прогнозом среднего

$$R^2 = 1 - \frac{\sum_i (y_i - \hat{y}_i)^2}{\sum_i (y_i - \bar{y})^2} = 1 - \frac{\text{SSE}}{\text{SST}}.$$

Здесь $y = (2, 4, 6)$, $\bar{y} = 4$, $\text{SST} = 8$; у модели $(3, 4, 5)$ $\text{SSE} = 2$.

$$R^2 = 1 - \frac{2}{8} = 0.75.$$

На одном evaluation-наборе $R^2 = 0$ соответствует прогнозу его среднего. Среднее test не используется при обучении модели; в формуле это опорный уровень оценки.

R^2 может быть отрицательным

На тех же $y = (2, 4, 6)$ модель предсказала $(5, 5, 5)$.

$$SSE = 9 + 1 + 1 = 11, \quad R^2 = 1 - \frac{11}{8} = -0.375.$$

Это хуже константного прогноза среднего данного evaluation-набора.

- ▶ R^2 не является долей правильно предсказанных объектов.
- ▶ На test значение может быть меньше нуля.
- ▶ Если все истинные значения одинаковы, знаменатель равен нулю и формула не определена.

Как выбрать метрику регрессии

Метрика	Что она сообщает
MAE	Типичную величину абсолютной ошибки в единицах target
MSE	Квадраты ошибок; удобно как функция потерь при обучении
RMSE	Масштаб ошибки в единицах target с большим весом крупных промахов
R^2	Качество относительно прогноза среднего на evaluation-наборе

На отчёте указываем и метрику ошибки, и baseline, и распределение остатков.

3

Линейная регрессия

Прямая как модель числового прогноза

Прямая и её параметры

Для одного признака x модель имеет вид

$$\hat{y} = b + wx.$$


b — прогноз при $x = 0$; w — изменение прогноза при увеличении x на единицу, если остальные признаки неизменны. Пример: $\hat{y} = 1 + 2x$. При $x = 0, 1, 2$

прогноз равен 1, 3, 5. Коэффициенты описывают модель и единицы признаков;

причинный эффект из них автоматически не следует.

Точки, прогнозы и остатки

Данные: $(x, y) = (0, 1), (1, 3), (2, 4)$. Возьмём $\hat{y} = 1 + 1.5x$.



При $x = 1$ остаток $y - \hat{y} = 3 - 2.5 = 0.5$; $MSE = (0^2 + .5^2 + 0^2)/3 = 1/12$.

Обучение: выбрать b и w

$$J(b, w) = \frac{1}{n} \sum_{i=1}^n (y_i - b - wx_i)^2.$$

Ищем параметры, минимизирующие ошибку на train. Это метод наименьших квадратов (OLS).

- ▶ Для многих признаков: $\hat{y} = b + \sum_{j=1}^p w_j x_j$.
- ▶ «Линейная» означает линейность по параметрам b, w_j ; признаки могут включать x^2 или другие преобразования.
- ▶ Качество выбранной модели оцениваем отдельно от данных обучения.

Какая прямая лучше

На точках $(0, 1)$, $(1, 3)$, $(2, 5)$ сравним два прогноза.

Модель	Прогнозы	SSE	MSE
$\hat{y} = 1 + x$	$(1, 2, 3)$	$0 + 1 + 4 = 5$	$5/3$
$\hat{y} = 1 + 2x$	$(1, 3, 5)$	0	0

Функция потерь превращает вопрос «какая прямая лучше?» в задачу минимизации.

Те же три точки в матричной записи

Для точек $(0, 1)$, $(1, 3)$, $(2, 5)$ строка X содержит единицу для b и значение x для w :

$$\underbrace{\begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{pmatrix}}_X \underbrace{\begin{pmatrix} b \\ w \end{pmatrix}}_{\beta} = \underbrace{\begin{pmatrix} b \\ b + w \\ b + 2w \end{pmatrix}}_{\hat{y}}, \quad y = \begin{pmatrix} 1 \\ 3 \\ 5 \end{pmatrix}.$$

Наша прежняя задача $J(b, w)$ теперь записывается как

$$J(\beta) = \frac{1}{2} \|X\beta - y\|_2^2.$$

Для новых признаков добавляем столбцы в X ; смысл ошибки и выбора коэффициентов не меняется.

Аналитический ответ и градиентный шаг

OLS

Если столбцы X независимы, решение единственно:

$$\hat{\beta} = (X^T X)^{-1} X^T y.$$


Для наших трёх точек $\hat{\beta} = (1, 2)^T$.

Формулу OLS сегодня не выводим; при вычислениях используют устойчивый решатель без явного обращения матрицы.

Градиентный спуск


Начинаем с произвольных b , w и уменьшаем J последовательными шагами. Ниже проследим их на этих же точках.

Коэффициент меняет прямую и loss



Для $x = (0, 1, 2)$, $y = (1, 3, 5)$ и фиксированного $b = 1$: $J(0) = 20/3$, $J(2/3) = 80/27$, $J(2) = 0$. Каждый w задаёт и прямую на данных, и одну точку на графике $J(w)$.

Производная и направление шага





При $w = 0$ наклон $J'(0) < 0$: движение вправо уменьшает ошибку.

$$w_{t+1} = w_t - \eta J'(w_t), \quad \eta > 0.$$

Минус перед производной ведёт в сторону убывания. η задаёт длину шага.


Два шага на одних данных



$$J(w) = \frac{5}{3}(w - 2)^2, \quad J'(w) = \frac{10}{3}(w - 2), \quad \eta = 0.1.$$


$w_0 = 0$; после шагов $w_1 = 2/3$, $w_2 = 10/9$. Прямая приближается к точкам, а её train-loss уменьшается.

Шаг перескакивает через минимум



Красная траектория из прошлой лекции пересекает узкую долину и попадает на другую сторону. Если шаг слишком велик, такие скачки могут мешать уменьшению loss .

Learning rate и изменение loss



Теперь снова одномерный пример $J(w) = \frac{5}{3}(w - 2)^2$, старт $w_0 = 0$. При $\eta = 0.01$ обучение идёт медленно; при $\eta = 0.8$ скачки увеличиваются и loss выходит за шкалу.

Проверка градиента

На наших точках $(0, 1)$, $(1, 3)$, $(2, 5)$ при $b = 1$, $w = 0$ прогнозы $(1, 1, 1)$. Ошибки $\hat{y} - y = (0, -2, -4)$.

$$\frac{\partial J}{\partial b} = \frac{2}{3}(0 - 2 - 4) = -4, \quad \frac{\partial J}{\partial w} = \frac{2}{3}(0 - 2 - 8) = -\frac{20}{3}.$$

В какую сторону изменятся b и w при положительном η ?

Оба увеличатся. При $\eta = 0.1$: $b_{new} = 1.4$, $w_{new} = 2/3$.


Градиент складывается из ошибок объектов

На том же старте $b = 1$, $w = 0$: вклад объекта в градиент MSE равен $(2e_i, 2e_ix_i)$, где $e_i = \hat{y}_i - y_i$.

Объект	x_i	y_i	e_i	вклад в $\partial J / \partial b$	вклад в $\partial J / \partial w$
1	0	1	0	0	0
2	1	3	-2	-4	-4
3	2	5	-4	-8	-16
Среднее				-4	-20/3

Batch усредняет все три вклада; SGD берёт один случайный вклад; mini-batch усредняет несколько. Поэтому траектории на следующем рисунке различаются.

Сколько объектов участвует в шаге



Batch использует все train-объекты, SGD — один случайный объект, mini-batch — небольшую группу. Шум траектории отличается; сравниваем при одинаковом числе просмотренных объектов.

Масштаб признаков и скорость обучения

При признаках в разных единицах поверхность loss может быть сильно вытянутой. Один learning rate для всех координат приводит к медленному продвижению или колебаниям.

- ▶ StandardScaler обучаем только на train, затем применяем к validation/test.
- ▶ Масштабирование часто помогает градиентной оптимизации и меняет численные значения коэффициентов.
- ▶ После fit проверяем график loss по шагам и ошибку на validation.


Остатки и границы модели

После обучения строим $y_i - \hat{y}_i$ против прогноза и важных признаков.

Наблюдение	Что проверить	
Изгиб остатков	Нелинейная зависимость или пропущенный признак	
Разброс растёт	Ошибка зависит от уровня target; важен выбор метрики	Линейная
Несколько больших остатков	Ошибка измерения, редкий подтип или реальный крайний случай	

регрессия может хорошо предсказывать и без нормальности признаков.
Статистические выводы о коэффициентах требуют отдельных предпосылок.

Когда линейная модель подгоняет шум



Учебный пример: 15 train-точек и полином степени 12, линейный по коэффициентам. OLS почти идеально описывает train, но сильно колеблется между точками. Ridge сглаживает решение.


Зачем штрафовать большие коэффициенты

В примере с 15 точками и полиномом степени 12 OLS почти запомнил train:

Модель	Train MSE	Validation MSE	$\ w\ _2$
OLS, $\lambda = 0$	0.0004	0.1481	782.3
Ridge, $\lambda = 0.01$	0.0086	0.0274	0.59

Мы минимизируем $J(w) = \text{MSE}_{\text{train}}(w) + \lambda \sum_j w_j^2$. Штраф допускает чуть большую ошибку на train ради менее резких коэффициентов. Здесь validation-ошибка уменьшается, но это проверка на данных, а не обещание для любой задачи. Признаки $x, x^2, \dots, x^{12}$ стандартизованы по train; свободный член не штрафуем.


Ridge и Lasso действуют на коэффициенты



Для $J = \text{MSE} + \lambda R(w)$: Ridge использует $R = \sum_j w_j^2$ и плавно сжимает веса; Lasso использует $R = \sum_j |w_j|$ и может сделать некоторые веса точно нулевыми. На графике — учебный пример с двумя ортогональными признаками.

Силу штрафа выбираем на validation

Те же 15 train-точек и та же модель с 12 степенями:



λ	Train	Validation
0	0.0004	0.1481
0.01	0.0086	0.0274
0.1	0.0157	0.0292

Из этих трёх вариантов берём 0.01. На полной кривой минимум около 0.028.

Что именно выбирает validation

Данные	Действие
Train	Для каждого кандидата λ отдельно обучаем scaler и Ridge.
Validation	Вычисляем MSE, сравниваем кандидатов и фиксируем λ .
Test	Один раз оцениваем выбранную процедуру после всех решений.

При кросс-валидации scaler обучается заново внутри каждого train-fold. Выбираем способ обучения, а не просто «красивую» кривую на train.

Полный эксперимент с регрессией

1. Определить объект, `target`, доступные на момент прогноза признаки и единицы ошибки.
2. Разделить `train/validation/test` с учётом времени или групп, если они есть.
3. На `train` обучить `scaler` и линейную модель; сравнить `baseline`, λ и метрики на `validation`.
4. Один раз оценить выбранную процедуру на `test`; изучить остатки и подгруппы.

Градиентный спуск минимизирует `train-loss`. Обобщение проверяет отложенная выборка.

Теоретический минимум

Классификация	Precision и recall зависят от порога; ROC использует TPR/FPR, PR показывает precision при данном recall. При редком классе проверяем рабочий порог.
Регрессия	MAE и RMSE измеряются в единицах target; MSE усиливает большие ошибки. $R^2 = 1 - \text{SSE}/\text{SST}$ может быть отрицательным.
Линейная модель	$\hat{y} = b + \sum_j w_j x_j$; OLS минимизирует train-MSE. В матричной записи $\hat{y} = X\beta$.
Градиент	$\beta \leftarrow \beta - \eta \nabla J$; градиент MSE усредняет вклады объектов. Большой шаг может перескакивать минимум.
Регуляризация	Ridge добавляет $\lambda \sum_j w_j^2$, Lasso добавляет $\lambda \sum_j w_j $. λ выбираем на validation, test используем после выбора.

Ко(т)нец презентации




От выбора метрики до проверки прогноза на новых данных.

Вопросы?

Резерв: ресемплинг

Подробности SMOTE для вопросов и самостоятельного чтения. Основной результат пары: метрику и рабочий порог проверяем на исходном распределении классов.

Как меняем обучающую выборку



Oversampling: повторяем редкие объекты.

Undersampling: удаляем часть частого класса.

Порог меняет решения модели. Ресемплинг меняет данные для обучения.

SMOTE: синтетический объект



Для x_i случайно выбираем x_j среди k_{SMOTE} ближайших объектов того же класса.

$$x_{new} = x_i + \alpha(x_j - x_i), \quad \alpha \sim U(0, 1).$$

При $x_i = (1, 1)$, $x_j = (5, 3)$, $\alpha = 0.25$:

$$x_{new} = (2, 1.5).$$

Синтетическая точка наследует метку редкого класса.


Ограничения SMOTE



- ▶ Отрезок может пересечь область другого класса.
- ▶ Точки около выбросов усиливают ошибочную структуру.
- ▶ Обычный SMOTE предполагает числовые признаки и осмысленную интерполяцию.

SMOTE не добавляет независимых наблюдений и не гарантирует улучшения качества.


SMOTE внутри обучающего фолда



Validation и test сохраняют исходные объекты и доли классов.

Реализация: `imblearn.pipeline.Pipeline`. На predict шаг ресемплинга пропускается.

Резерв: почему Lasso обнуляет вес



Для одного коэффициента $(w - 0.7)^2 + 1.5|w|$ минимум достигается при $w = 0$. У штрафа $|w|$ есть угол в нуле: слабый коэффициент может стать точно нулевым.