

Лекция 6

Деревья решений и важность признаков

Машинное обучение · 6 октября 2026

Лектор

Елизавета Власова

Практики

Кирилл Захаров

Михаил Подсытник

Игорь Толстокулаков

Правила и деревья решений

От интерпретируемой закономерности к
дереву

Интерпретируемые закономерности

Закономерность φ можно назвать **интерпретируемой**, если она:

- ▶ сформулирована естественным языком;
- ▶ зависит от небольшого числа признаков или условий.

Пример из русского языка:

если наречие оканчивается на шипящую букву, в конце пишется «ь»: *настежь*, *сплошь*.

У правила есть исключения: уж, замуж, невтерпёж.

Информативные закономерности

Пусть $\varphi(x) = 1$ означает, что правило выполнено, а c — интересующий нас класс.

$$p_c(\varphi) = |\{x_i : \varphi(x_i) = 1, y_i = c\}| \longrightarrow \max$$

$$n_c(\varphi) = |\{x_i : \varphi(x_i) = 1, y_i \neq c\}| \longrightarrow \min$$

- ▶ p_c : истинно положительные срабатывания.
- ▶ n_c : ложно положительные срабатывания.


Желательно охватить больше объектов класса c и меньше объектов других классов.

Какие правила можно выделить?

День	Погода	Температура	Влажность	Ветер	Играем?
1	Sunny	Hot	High	Weak	No
2	Cloudy	Hot	High	Weak	Yes
3	Sunny	Mild	Normal	Strong	Yes
4	Cloudy	Mild	High	Strong	Yes
5	Rainy	Mild	High	Strong	No
6	Rainy	Cool	Normal	Strong	No
7	Rainy	Mild	High	Weak	Yes
8	Sunny	Hot	High	Strong	No
9	Cloudy	Hot	Normal	Weak	Yes
10	Rainy	Mild	High	Strong	No

Что такое правило? Какие правила согласуются с этими данными?

Дерево по правилам



Путь от корня до листа объединяет несколько условий.

Например: **Rainy** и **Strong wind** $\Rightarrow$ **No**.

Где брать правила?

Откуда берутся правила

- ▶ Создавать самостоятельно.
- ▶ Заимствовать у экспертов.
- ▶ Обучать по данным.

Как обучать правила

- ▶ Алгоритмы оптимизации.
- ▶ Эвристические методы.
- ▶ Алгоритмы машинного обучения.

Рассмотрим, как дерево решений выбирает правила по обучающей выборке.


Дерево решений

Алгоритм классификации и регрессии.


Элемент	Что содержит
Внутренний узел	Разделяющее правило: вопрос об объекте.
Ребро	Один из ответов на вопрос в родительском узле.
Лист	Прогноз: класс для классификации или число для регрессии.

В листе классификации обычно выбираем наиболее частый класс; доли классов дают оценку вероятностей.

Дерево решений: пример



Тот же пример: другое дерево



Теперь первый вопрос —
возраст.

**Какой ответ получит студент
25 лет?**

Какие признаки понадобились
на этом пути?

2

Обучение дерева

Выбор правила, критерия и момента
остановки

Рекурсивное построение дерева

Есть множество допустимых правил B и критерий качества разбиения.

1. Помещаем обучающую выборку S в корень.
2. Если все объекты одного класса, создаём лист.
3. Иначе выбираем правило $b \in B$ и делим S на подмножества S_j .
4. Если рост допустим, повторяем процедуру в дочерних узлах. При остановке сохраняем наиболее частый класс.
5. После построения при необходимости подрезаем дерево.

Жадный алгоритм выбирает лучший текущий сплит; глобально оптимальное дерево не гарантируется.

Какие вопросы осталось решить?

1. Как выбирать **разделяющие правила**?
2. Как выбирать **критерий ветвления**?
3. Как выбирать **критерий остановки**?
4. Как **подрезать дерево**?

Выбор разделяющего правила

Часто используем простые проверки одного признака $f_j(x)$:

$$b(x) = 1\{f_j(x) > t\}$$

$$b(x) = 1\{f_j(x) = d\}$$

t — порог числового признака; d — значение категории.

В бинарном дереве ответ делит объекты на две группы: условие выполнено или нет.

Как выбрать правило?

- ▶ Рассмотреть допустимые правила и выбрать наиболее информативное.
- ▶ Для числового признака рассмотреть границы диапазонов.
- ▶ Исключить варианты, которые создают слишком маленькие группы.

В более общих правилах можно объединять диапазоны значений.

В стандартном CART один узел проверяет **один порог**; сложный диапазон можно выразить несколькими узлами.

Критерии неоднородности узла

p_k — доля класса k в узле; K — число классов.

Gini

$$G(S) = 1 - \sum_{k=1}^K p_k^2$$

Для двух равных классов: $G = 0.5$.

Энтропия

$$H(S) = - \sum_{k=1}^K p_k \log_2 p_k$$

Для двух равных классов: $H = 1$ бит.

Если все объекты одного класса, оба критерия равны **нулю**.

Соглашение: $0 \log_2 0 = 0$. Это статистики train-узла, а не метрики на validation.

Выигрыш от разбиения

Правило разделило узел S на дочерние узлы $S_1, \dots, S_m$.

$$\text{Gain}(S) = I(S) - \sum_{j=1}^m \frac{|S_j|}{|S|} I(S_j).$$

I — Gini или энтропия. Размеры дочерних узлов задают **веса**.

- ▶ После хорошего сплита взвешенная неоднородность уменьшается.
- ▶ Выбираем допустимое правило с максимальным Gain.
- ▶ Для энтропии это **Information Gain**.

Как искать порог числового признака?

Полный перебор кандидатов

- ▶ Отсортировать значения признака в узле.
- ▶ Рассмотреть пороги между соседними уникальными значениями.
- ▶ Оценить выигрыш каждого допустимого сплита.

Гистограммный поиск

- ▶ Разбить значения на B бинов, например по квантилям.
- ▶ Собрать статистики по бинам.
- ▶ Искать лучшую границу; после агрегации проход занимает $O(B)$.

Рассчитаем энтропию

Отдельный погодный пример: **14 дней, 9 Yes и 5 No.**

День	Погода	Играем?
1	Sunny	No
2	Sunny	No
3	Overcast	Yes
4	Rainy	Yes
5	Rainy	Yes
6	Rainy	No
7	Overcast	Yes

День	Погода	Играем?
8	Sunny	No
9	Sunny	Yes
10	Rainy	Yes
11	Sunny	Yes
12	Overcast	Yes
13	Overcast	Yes
14	Rainy	No

До разделения:

$$H(S) = -\frac{9}{14} \log_2 \frac{9}{14} - \frac{5}{14} \log_2 \frac{5}{14}$$
$$H(S) \approx 0.940$$

Энтропия после разделения по погоде

Погода	Yes	No	Энтропия
Sunny	2	3	$-\frac{2}{5} \log_2 \frac{2}{5} - \frac{3}{5} \log_2 \frac{3}{5} \approx 0.971$
Overcast	4	0	0
Rainy	3	2	$-\frac{3}{5} \log_2 \frac{3}{5} - \frac{2}{5} \log_2 \frac{2}{5} \approx 0.971$

Почему у Overcast энтропия равна нулю?

Information Gain: результат


$$H_{\text{после}} = \frac{5}{14} \cdot 0.971 + \frac{4}{14} \cdot 0 + \frac{5}{14} \cdot 0.971 \approx 0.694.$$

$$\text{IG} = H(S) - H_{\text{после}} \approx 0.940 - 0.694 \approx 0.247 \text{ бита.}$$

Разделение по погоде уменьшило неопределённость класса.

Здесь три исходные ветви. В бинарном CART сравниваются разбиения на две части.

Критерий остановки: сравним варианты



В корне 980 объектов класса 0 и 20 класса 1.

Что улучшилось после сплита? Как сравнить А и В?

Остановка по чистоте и выигрышу

- ▶ **Чистый текущий узел:** все объекты одного класса, дальше разделять его не нужно.
- ▶ **Слишком малый выигрыш:** лучший допустимый сплит почти не уменьшает неоднородность.

В предыдущем примере Gini корня 0.0392:

$$\text{Gain}_A \approx 0.0176, \quad \text{Gain}_B \approx 0.0167.$$

При Gini выбираем **A**, если остальные ограничения допускают сплит.

Чистый дочерний узел — допустимый результат, а не причина запретить разделение.

Остановка по размеру и глубине

Ограничение	Смысл
<code>min_samples_split</code>	Не разделять узел, если в нём слишком мало объектов.
<code>min_samples_leaf</code>	Не создавать слишком маленькие листья.
<code>max_depth</code>	Ограничить глубину дерева.
<code>max_leaf_nodes</code>	Ограничить общее число листьев.

Значения ограничений выбираем по **validation** или **CV**, а не по качеству на train.

Остановка через статистические тесты

Другой подход: проверять связь признаков с классом внутри текущего узла.

Если убедительных свидетельств связи нет, остановить рост и создать лист.

Какие статистические тесты могут пригодиться для категориального признака и класса?

Это отдельная стратегия построения дерева; стандартный CART выбирает сплиты по уменьшению неоднородности.

Как подрезать дерево?

1. Построить дерево с достаточно подробными правилами.
2. Заменять поддеревья листьями, получая более простые варианты.
3. Выбирать степень упрощения по validation/CV.

Например, cost-complexity pruning сочетает неоднородность листьев на train и их число:

$$R_{\alpha}(T) = R(T) + \alpha |\text{leaves}(T)|.$$

При большем α сильнее штрафует сложность. В scikit-learn: `ccp_alpha`.

3

Регрессионные деревья

Числовой прогноз в листе и переобучение


Что меняется в задаче регрессии?

В листе возвращаем **число**
вместо класса.


При квадратичной ошибке
оптимальный постоянный
прогноз — среднее:

$$\hat{y}_L = \frac{1}{|L|} \sum_{i \in L} y_i.$$

Сплит выбираем по уменьшению
взвешенной внутригрупповой
MSE.




Что плохого можно увидеть на картинке?



Где дерево начинает подстраиваться под отдельные точки?

Как проверить, помогает ли большая глубина на новых данных?


Как дерево переобучается



Переобучение: модель подстраивается под случайные особенности train, которые не повторяются на новых данных.

Чем подробнее разбиение, тем легче выделить отдельную шумную точку в собственный лист.

Почему маленький лист запоминает шум




В листе один объект:

$$\hat{y}_L = y_i = f(x_i) + \varepsilon_i.$$

Ошибка на этом train-объекте равна нулю.

На новом объекте случайная ошибка будет другой. Узкая ступенька её не предсказывает.

Ошибка на train и validation




Train: большая глубина позволяет лучше подогнать обучающие точки.

Validation: после некоторой глубины ошибка растёт. Выбираем сложность по новым данным.

Один фиксированный эксперимент: 80 train-объектов и 2000 независимых validation-объектов.

Как уменьшить переобучение



	Без ограничения	Минимум 5 в листе	Подрезка $\alpha = 0.01$
Train MSE	0.000	0.105	0.064
Validation MSE	0.316	0.191	0.231

Ограничение роста не даёт создать маленькие листья; подрезка удаляет ветви уже построенного дерева.

Как выбрать сложность дерева

	Train	Validation
Недообучение	Высокая ошибка	Высокая ошибка
Переобучение	Низкая ошибка	Заметно хуже train

1. Обучаем варианты глубины, размера листа и степени подрезки на train.
2. Выбираем параметры по validation или кросс-валидации.
3. Один раз оцениваем выбранную модель на отложенном test.


Нулевая ошибка на train не означает хорошую модель.

4

Важность признаков

Как дерево использует признаки и что происходит с качеством

Какие признаки важны в этом дереве?



В корне —
overcast; ниже —
Temperature.

Кто важнее?

Достаточно ли
первого сплита или
числа узлов?

MDI: суммируем вклад разбиений

Mean Decrease in Impurity: насколько признак уменьшил неоднородность обучающей выборки.

$$\Delta_t = \frac{n_t}{N} \left(I_t - \frac{n_L}{n_t} I_L - \frac{n_R}{n_t} I_R \right).$$

$$A_j = \sum_{t: \text{feature}(t)=j} \Delta_t, \quad \text{MDI}_j = \frac{A_j}{\sum_k A_k}.$$

- ▶ N : размер train; n_t : число объектов в текущем узле.
- ▶ Суммируем **все** узлы, где использовался признак j .
- ▶ Нормируем вклады; при ненулевом суммарном вкладе сумма MDI равна 1.

MDI на исходном погодном дереве

Для `overcast` есть только корневое разделение:

$$A_{\text{overcast}} = \frac{45}{98} - \frac{10}{14} \cdot \frac{1}{2} - \frac{4}{14} \cdot 0 = \frac{5}{49} \approx 0.102.$$

Все листья чистые, поэтому суммарное уменьшение Gini равно Gini корня:

$$A_{\text{Temperature}} = \frac{45}{98} - \frac{5}{49} = \frac{5}{14} \approx 0.357.$$



Признак	Суммарный вклад	MDI после нормировки
<code>overcast</code>	0.102	0.222
<code>Temperature</code>	0.357	0.778

Первый сплит не обязан давать наибольшую суммарную важность.

Два одинаково хороших дерева

Два признака описывают одну температуру: $T_K = T_C + 273.15$. Класс: «тепло», если $T_C > 20$.



T_C	10	15	25	30
T_K	283.15	288.15	298.15	303.15
Класс	No	No	Yes	Yes



Какие значения MDI получат два признака?

Одинаковое качество, разная MDI

На новых объектах $T_C = 12, 18, 22, 28$ оба дерева дают правильные ответы: No, No, Yes, Yes.



В каждом дереве один сплит: $A_j = 0.5$ для выбранного признака и 0 для другого.

MDI зависит от выбранных правил. Взаимозаменяемая информация может целиком приписаться одному из столбцов.

Ограничения MDI

Признак	Возможности поиска сплита
Признак 0/1	Одно нетривиальное разбиение.
Непрерывный шум	Много порогов: больше возможностей случайно уменьшить train-неоднородность.

Глубокое дерево может использовать шум, чтобы запомнить train.

Большая MDI означает вклад в построенное дерево.

Полезность на новых данных нужно проверить отдельно.

Permutation importance

1. Проверяем качество обученной модели на **validation**: s .
2. Перемешиваем один столбец X_j между строками; y и остальные столбцы сохраняем.
3. Считаем качество s_j^{perm} без переобучения модели.
4. Повторяем с разными перестановками и усредняем разность.

$$PI_j = s - \text{mean}(s_j^{\text{perm}}).$$

Здесь s — score, где больше лучше. Для MSE: $PI_j = \text{MSE}_{\text{perm}} - \text{MSE}_{\text{base}}$.

Перестановка ветра: погодный пример

Берём четыре Rainy-строки из первой таблицы. У готового дерева: **Strong** → **No**, **Weak** → **Yes**.

День	Ветер	Играем?	После перестановки	Новый прогноз
5	Strong	No	Weak	?
6	Strong	No	Strong	?
7	Weak	Yes	Strong	?
10	Strong	No	Strong	?

Какие ответы теперь даст дерево? Что произойдёт с ассигасу?

Повтор исходных строк иллюстрирует механизм. Реальную полезность оцениваем на validation по нескольким перестановкам.

Результат одной перестановки

	До	После
Правильные ответы	4 из 4	2 из 4
Accuracy	1.0	0.5

$$s - s^{\text{perm}} = 1.0 - 0.5 = 0.5.$$

Условия дерева остались прежними. Изменился только ветер в строках.

Вывод: прогноз этого дерева зависит от ветра.

0.5 относится к одной перестановке четырёх строк, а не к общему рейтингу признаков.

Другие перестановки того же ветра

Есть три значения Strong и одно Weak. После перестановки Weak может попасть в любую из четырёх строк.

В какой день попал Weak	Accuracy после	Падение accuracy
5	0.5	0.5
6	0.5	0.5
7	1.0	0.0
10	0.5	0.5

$$\text{Среднее падение} = \frac{0.5 + 0.5 + 0 + 0.5}{4} = 0.375.$$

Одна перестановка может дать ноль даже для используемого признака.

В этом маленьком примере перебрали все варианты; обычно усредняем несколько случайных перестановок на validation.

Переставим влажность на ветке Rainy

На ветке **Rainy** дерево проверяет только ветер. Влажность переставляем, ветер оставляем прежним.

День	Влажность до	Влажность после	Прогноз до и после
5	High	Normal	No
6	Normal	High	No
7	High	High	Yes
10	High	High	No

$$PI_{\text{Humidity}} = 1.0 - 1.0 = 0.$$

Для **этих строк** прогноз не зависит от влажности.

Но на ветке Sunny влажность используется! Ноль на подмножестве не означает ноль на всей выборке.

PI в двух равноценных деревьях

Вернёмся к T_C и T_K . На новых объектах оба дерева имеют ассигуру 1.0.

Меняем порядок **одного** столбца на обратный. Например:

$T_C = 12, 18, 22, 28 \rightarrow 28, 22, 18, 12$. Второй столбец и классы оставляем прежними.

Переставленный столбец	Падение ассигуру у А	Падение ассигуру у В
T_C	1.0	0.0
T_K	0.0	1.0

PI тоже оценивает конкретную модель: А использует T_C , В использует T_K .

Перестановка нарушает связь $T_K = T_C + 273.15$: получаются сочетания, которых не бывает в исходных данных.

Как читать permutation importance

Важность	Интерпретация
Большая	Качество этой модели на этих данных
положительная	ухудшилось без исходной связи признака.
Около нуля	Перестановка мало повлияла; проверьте разброс, качество модели и корреляции.
Отрицательная	После перестановки стало лучше: возможны шум оценки или вредная зависимость модели.

Повторения оценивают разброс **перестановок**; другие train-split и модели могут дать другой рейтинг.

Если признаки коррелируют

Пусть x_A и x_B несут почти одну и ту же информацию.

Что делаем	Что сохраняется
Перестановка x_A	Исходная информация в x_B .
Перестановка x_B	Исходная информация в x_A .
Одна перестановка для пары	Разрушаем связь с target, сохраняя связь внутри пары.

Низкая индивидуальная важность не доказывает, что информация пары бесполезна.

Эффект зависит от модели: одно дерево может выбрать одну копию и игнорировать другую.

Две оценки важности

	MDI	Permutation
Данные	Статистики train-узлов	Выбранный набор, обычно validation
Оценка	Уменьшение impurity	Изменение выбранного score
Шкала	Доли, обычно сумма 1	Единицы метрики; сумма не обязана быть 1
Модель	Дерево / ансамбль деревьев	Любая готовая модель
Ограничения	Много порогов, переобучение	Корреляции, разброс, качество модели

Ни одна оценка сама по себе не доказывает причинный эффект.

Можно ли удалить неважный признак?

Рейтинг — гипотеза для нового эксперимента: **убрать признаки, переобучить и проверить качество.**

Часть данных	Что делаем
Train-часть каждого CV split	Оцениваем важность, выбираем признаки и обучаем модель. При необходимости используем внутренний split.
Validation-часть CV split	Проверяем всю процедуру отбора и обучения.
Финальный test	Используем после выбора процедуры.

Нельзя выбрать top- k по всему dataset, а затем считать CV независимой проверкой.

Теоретический минимум

- ▶ Путь от корня до листа задаёт набор правил и прогноз.
- ▶ Обучение жадно выбирает допустимый сплит по взвешенному уменьшению Gini, энтропии или MSE.
- ▶ Рост ограничивают чистота узла, выигрыш, размер и глубина; дерево можно подрезать.
- ▶ При MSE прогноз листа — среднее. Train-ошибка не оценивает обобщение; сложность выбираем по validation/CV.
- ▶ MDI суммирует вклад в train-разбиения. PI измеряет изменение качества фиксированной модели при перестановке.
- ▶ Проверяем шум, корреляции и качество после отбора. Важность не доказывает причинность.

Ко(т)нец презентации


Вопросы?

На следующей паре:

случайный лес и бустинг.




От дерева к ансамблю



Слева отдельные деревья сильнее меняются при изменении выборки. Усреднение помогает уменьшить разброс прогнозов.

Композиция базовых алгоритмов



Берём семейство базовых алгоритмов и объединяем их ответы.

В бэггинге каждое дерево обучается на своей **bootstrap-выборке**: выбираем строки с повторениями.

Регрессия: средний прогноз.
Классификация: голосование или усреднение вероятностей.


Случайный лес

Random Forest: ансамбль отдельно обученных деревьев решений.

1. Для каждого дерева создаём bootstrap-выборку строк.
2. В каждом узле рассматриваем случайное подмножество признаков для поиска сплита.
3. Агрегируем прогнозы деревьев.

В scikit-learn RF усредняет вероятности в классификации и числовые прогнозы в регрессии.

Случайные признаки при разбиении



Случайный набор кандидатов выбирается **в каждом узле**, а не один раз на всё дерево.

Это помогает строить разные деревья и уменьшать корреляцию их ошибок.